# Apache kafka quick start

Site officiel: https://kafka.apache.org

STEP 1: DOWNLOAD AND INSTALL KAFKA

https://dlcdn.apache.org/kafka/3.7.0/kafka 2.13-3.7.0.tgz

#### STEP 2: START THE KAFKA ENVIRONMENT

# Start the ZooKeeper service

 $\label{lem:c:users} $$C:\Users\RAMESH\Downloads\kafka>.\bin\windows\zookeeper-server-start.bat .\config\zookeeper.properties$ 

# Start the Kafka broker service

C:\Users\RAMESH\Downloads\kafka>.\bin\windows\kafka-server-start.bat .\config\server.properties

### **STEP 3: CREATE A TOPIC TO STORE YOUR EVENTS**

C:\Users\RAMESH\Downloads\kafka>.\bin\windows\kafka-topics.bat --create --topic topic\_demo --bootstrap-server localhost:9092

#### STEP 4: WRITE SOME EVENTS INTO THE TOPIC

C:\Users\RAMESH\Downloads\kafka>.\bin\windows\kafka-console-producer.bat --topic topic\_demo --bootstrap-server localhost:9092

>hello world

>topic demo

### **STEP 5: READ THE EVENTS**

C:\Users\RAMESH\Downloads\kafka>.\bin\windows\kafka-console-consumer.bat --topic topic\_demo --from-beginning --bootstrap-server localhost:9092

hello world

topic demo

## Kafka-connect

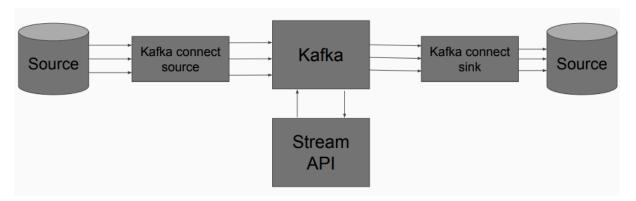
Connect kafka avec les systèmes externes (base de données, système de fichier,...)

2 catégories :

Connecteur source : prendre les données du monde extérieur et les connecter avec KAFKA.

Exemple: lire des messages depuis une BDD et les envoyer sur un topic kafka

<u>Connecteur sink</u>: prendre les données depuis un topic kafka et les envoyer à une destination par exemple HDFS (si on veut créer des fichiers sous HDFS)



- Test 1 : connect source file stream
- Test 2 : connect sink file stream
- Test 3 : connet sink désérialisation JSON

### A. CONNECT SOURCE FILE STREAM

1. lancer le connecteur en mode standalone: (ou dustributed)

C:\kafka\bin\windows>.\connect-standalone.bat ..\..\kafka-connect\connect-standalone.properties "..\..\kafka-connect\connect-file-source.properties

2. lancer un consumer sur un topic de test pour tester :

.\bin\windows\kafka-console-consumer.bat --topic test-autre--from-beginning --bootstrap-server localhost:9092

producer: écrire sur test-source.txt -> aller à la ligne et sauvegarder

Le consumer va lire dans un fichier text

```
C:\kafka>.\bin\windows\kafka-console-consumer.bat --topic test-autre --bootstrap-server localhost:9092
hi
hello
imene
michelin
capgemini

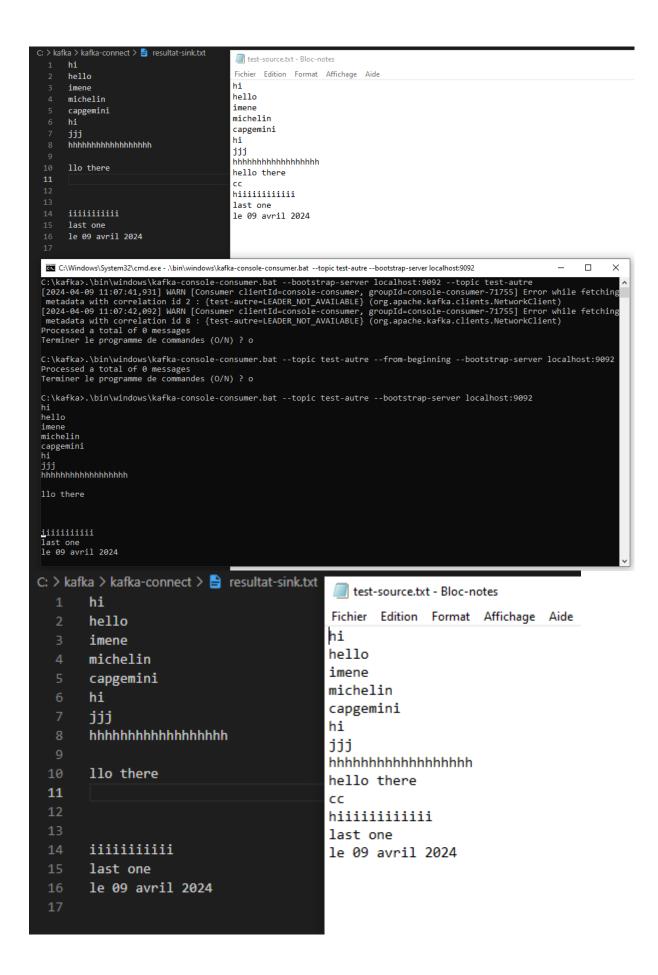
test-source.txt - Bloc-notes
Fichier Edition Format Affichage Aide
hi
hello
imene
michelin
capgemini
capgemini
```

### **B. Linverse: CONNECT SINK FILE STREAM**

1. lancer le source et le sink en mode standalone (il faut arrêter celui d'avant car deja utilisé)

.\connect-standalone.bat ..\..\kafka-connect\connect-standalone.properties ..\..\kafka-connect\connect-file-sink.properties

2. ecrire dans le source et voir le resultat dans le sink



### **C. CONNECT SINK DESERIALISATION JSON**

1. modifier standalone.properties

bootstrap.servers=localhost:9092

key.converter=org.apache.kafka.connect.json.JsonConverter

value.converter=org.apache.kafka.connect.json.JsonConverter

key.converter.schemas.enable=false

value.converter.schemas.enable=false

offset.storage.file.filename=C:\\kafka\\offset-storage.offsets

offset.flush.interval.ms=10000

plugin.path=C:\\kafka\\libs

2. lancer le source et le sink en mode standalone (il faut arrêter celui d'avant car deja utilisé)

C:\kafka\kafka-connect>..\bin\windows\connect-standalone.bat connect-standalone.properties connect-file-sink.properties connect-file-source.properties

- 3. Créer le producer : C:\Users\RAMESH\Downloads\kafka>.\bin\windows\kafka-console-producer.bat --topic test-autre --bootstrap-server localhost:9092 et tapez : {"Prenom":"Imene", "Nom":"Dupond"}
- 4. lire sur le fichier resultat-sink.txt : {Prenom=Imene, Nom=Dupond}

```
sasl.out/bearer_juks_endpoint_erty_backoff_mas = 1000
sasl.out/bearer_sub_clais_mame = sub_sasl.out/bearer_sub_clais_mame = sub_sasl.out/bearer_sub_clais_sub_clais_mame = sub_sasl.out/bearer_sub_clais_sub_clais_mame = sub_sasl.out/bearer_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_clais_sub_cla
```

```
1.Renomer à true
```

3. relacer le kafka-connect

```
4. tester avec :
{"schema":{ "type" : "struct", "fields" : [ { "type" : "string", "optional" : "false", "field" : "Prenom"},{
"type": "string", "optional": "false", "field": "Nom" }], "optional": "false", "name": "users"},
"payload": {"Prenom":"Imene", "Nom":"OUAHRANI"}}
qui est:
"schema":
  {
    "type": "struct",
    "fields" : [
      {
         "type": "string",
         "optional": "false",
         "field": "Prenom"
      },
      {
         "type": "string",
         "optional": "false",
         "field": "Nom"
      }
    ],
    "optional": "false",
    "name": "users"
  },
  "payload": {"Prenom":"Imene", "Nom":"OUAHRANI"}
}
```

5. lire sur le fichier resultat-sink.txt : Struct{Prenom=Imene,Nom=OUAHRANI}

1.modier

name=local-file-sink

connector.class=FileStreamSink

tasks.max=1

 $file = C: \\ kafka \\ kafka-connect \\ resultat-sink.txt$ 

topics=test-autre

transforms=Udemy

transforms.Udemy.type=org.apache.kafka.connect.transforms.MaskField\$Value transforms.Udemy.fields=nom

relancer

5. lire sur le fichier resultat-sink.txt : Struct{Prenom=Imene,Nom=}

# KAFKA STREAM API

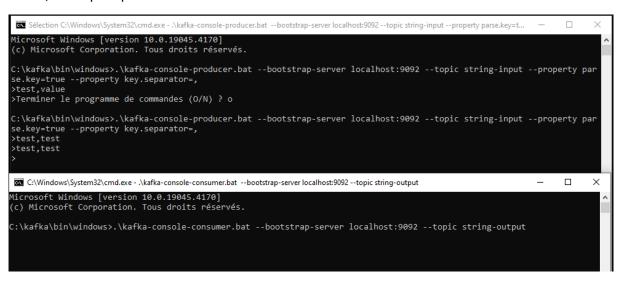
Remarque : la version de kafka installé c'est la 3.7.0 mais la majorité des tutoriels utilise la version 2.x

### **Basique**

• Sépareteur virgule clé, valeur <k, v> : ecrire test, value sur un producer et lire value sur un consumer

## filter

• Ici, on ne peut pas recevoir car la taille est < 5



• Ici, on va bien recevoir car la taille > 5

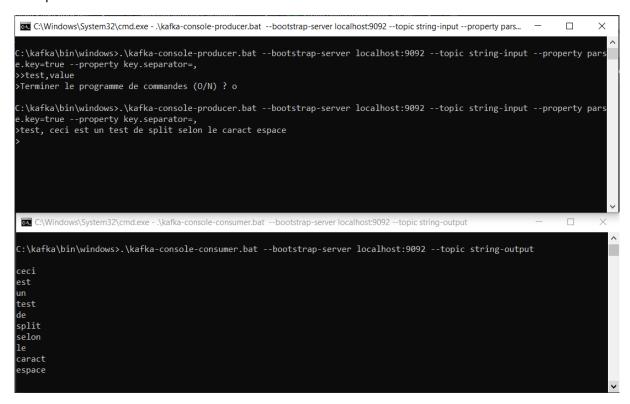


# mapValue

Renvoie une value en majuscule

## flatMap

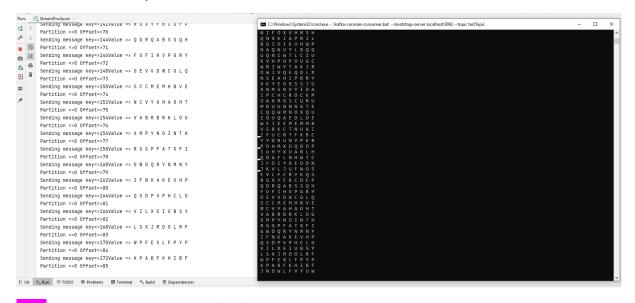
• Split selon un caractere



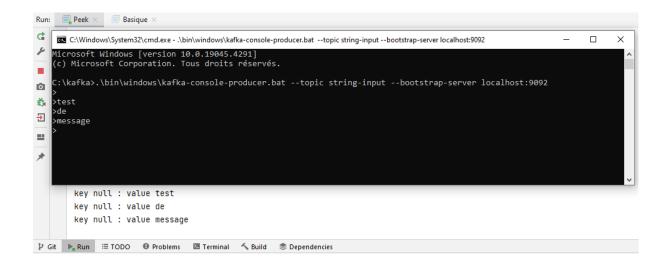
### forEach



### kafka stream producer



Peek = foreeach mais avec plus d'opérations



# Word acount : compter combien de fois un mot a été écrit sur le producer

```
C:\Windows\System32\cmd.exe - .\kafka-console-producer.bat --bootstrap-server localhost:9092 --topic string-input
                                                                                                               ×
    osoft Windows [version 10.0.19045.4291]
(c) Microsoft Corporation. Tous droits réservés.
C:\kafka\bin\windows>.\kafka-console-producer.bat --bootstrap-server localhost:9092 --topic string-input
>UU
>Terminer le programme de commandes (O/N) ?
C:\kafka\bin\windows>.\kafka-console-producer.bat --bootstrap-server localhost:9092 --topic string-input
>hello kafka stream
>imene kafka stream level awesoome
>hello kafka !!
>imene imene
>hi hi
C:\kafka\bin\windows>.\kafka-console-consumer.bat --bootstrap-server localhost:9092 --topic string-output --property pri
izer --property value.deserializer=org.apache.kafka.common.serialization.LongDeserializer
hello
kafka
imene
```